

선형대수학팀

3팀

김수인
오정민
이수진
홍세정
강현주

INDEX

1. 고유값과 고유벡터

2. PCA

3. SVD

4. SVD to Data

■ 고유값과 고유벡터 (Eigenvalue & Eigenvector)

선형 변환을 벡터의 스칼라 곱으로 표현 가능 !

$$\underbrace{Av}_{\text{=고유벡터}} = \underbrace{\lambda v}_{\text{=고유값}}$$



*고유벡터

-변환 후에도 자신의 고유한 span 공간에 남아있는 벡터

*고유값

-고유벡터를 얼마나 늘이고 줄였는지에 대한 값

■ Why Eigen?



(고유벡터=회전축, 고유값=축의 변환 정도)

고유벡터는 선형 변환 후에도 그대로 남아있다

=즉, 변환의 **회전축**으로 활용 가능

■ 고유값 분해 (Eigen decomposition)

고유값 분해 : “ $Av = \lambda v$ ” 식에서 A 분해하기

< N x N 행렬 >

= n개의 고유벡터와 고유값을 갖는다.

$$A = [v_1 \ v_2 \ \dots \ v_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ 0 & & \ddots \\ & & & \lambda_n \end{bmatrix} [v_1 \ v_2 \ \dots \ v_n]^{-1}$$



$$A = Q \Lambda Q^{-1}$$

■ 고유값 분해 (Eigen decomposition)

고유값 분해 : “ $Av = \lambda v$ ” 식에서 A 분해하기

< N x N 행렬 >
※Condition※

$$A = Q\Lambda Q^{-1} \quad \rightarrow \quad A = Q\Lambda Q^T$$

1) A가 정방행렬일 때

2) 모든 column이 선형독립일 때

>> 위 두 조건이 충족되어야 고유값 분해 가능!!

■ PCA란?


PCA

:(Principal Component Analysis) 주성분분석

- 원래 데이터의 분산을 최대한 보존할 수 있는 방향으로 축을 변형시킨 '주성분'을 찾는 기법
- 자주 사용되는 차원 축소 기법! → Projection 방법을 사용

■ Why Eigenvector is PC?


Ex. R2 공간



- 빨간색 고유벡터와 수직을 이루는 파란색 벡터 역시 선형변환 이후에도 방향이 변하지 않음!
- 파란색 벡터도 또한 고유벡터!

■ Why Eigenvector is PC?

Ex. R2 공간



데이터가 고유벡터 방향으로 분산된 정도


⇒ 고유값 ←

고유값이 클수록 분산을 잘 설명하는 축이 된다!

따라서 이 경우 빨간색 벡터로 Projection!

■ Singular Value Decomposition : 특이값분해

$$A = U \Sigma V^T$$



■ SVD : 특이값분해

행렬 분해!

 A  U Σ V^T 

목적?

서로 orthogonal한
벡터 집합

선형변환

여전히 orthogonal한
벡터 집합 찾으려고!

■ SVD : 무엇이 좋은가?


$$\begin{array}{c} A \\ \begin{array}{|c|c|c|} \hline A_k & & \\ \hline \end{array} \end{array} = \begin{array}{c} U \\ \begin{array}{|c|c|c|} \hline U_1 & U_2 & U_m \\ \hline \end{array} \end{array} \times \begin{array}{c} \Sigma \\ \begin{array}{|c|c|c|} \hline \sigma_1 & & 0 \\ \hline 0 & & \sigma_n \\ \hline \dots & 0 & \dots \end{array} \end{array} \times \begin{array}{c} V^T \\ \begin{array}{|c|} \hline V_1^T \\ \hline V_n^T \\ \hline \end{array} \end{array}$$

$$= \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_n u_n v_n^T$$

행렬을 여러 레이어로 쪼개어 볼 수 있다!


■ SVD와 PCA : 표준화된 X의 공분산 행렬 구하기

특이값 분해



V 행렬이


곧 공분산 행렬의 고유벡터




PC값 계산 빠르고 정확

 `prcomp()`

고유값 분해



PCA



공분산행렬

계산량 많아 느리다!

 `princomp()`